TRABAJO PRÁCTICO Nº1 – PROCESAMIENTO DE DATOS

ANÁLISIS DE DESASTRES NATURALES ENTRE 1970 Y 2021

Alumna: Julia Belén Carrillo

DNI: 34.811.824

1. Introducción

El objetivo de este trabajo práctico es aplicar un proceso de Extracción, Transformación y Carga de datos (ETL) para realizar un análisis exploratorio de los desastres naturales registrados en el mundo entre los años 1970 y 2021.

Para ello utilicé el dataset sugerido por el profesor, que contiene información sobre los diferentes tipos de desastres, su ubicación geográfica, las fechas en las que ocurrieron y sus consecuencias.

El trabajo se desarrolla utilizando Python y la librería Pandas para la lectura, limpieza, transformación y análisis de los datos, también Matplotlib para realizar los gráficos.

A través de este análisis se busca identificar patrones, comparar la frecuencia de los distintos tipos de desastres según su ubicación geográfica y estudiar su evolución durante las últimas dos décadas del período seleccionado.

El proyecto se organiza mediante una arquitectura ETL modular, separando las tareas de extracción, transformación y generación de resultados en diferentes archivos Python.

2. Descripción del dataset

Se utilizó un conjunto de datos EM-DAT sobre desastres naturales ocurridos en diferentes países del mundo entre 1970 y 2021.

El archivo original está en formato CSV y contiene 14.644 registros y 47 columnas. Cada registro corresponde a un evento de desastre documentado.

Entre las principales variables que se utilizaron en el análisis se encuentran:

- Disaster Type: tipo de desastre.
- Country: país donde ocurrió.
- Continent: continente al que pertenece el país.
- Region: región geográfica correspondiente.
- Start Year y Start Month: año y mes de inicio del desastre.
- Total Affected: cantidad de personas afectadas.

Estas variables permiten estudiar la distribución temporal y geográfica de los desastres, comparar su frecuencia y analizar sus consecuencias sobre la población.

Durante la exploración inicial se identificaron valores faltantes en algunas columnas, por lo que fue necesario evaluar su tratamiento antes de realizar los análisis.

3. Arquitectura del proyecto

Para el desarrollo del trabajo elegí una arquitectura ETL tradicional y modular, que permite organizar el procesamiento de los datos en 3 etapas: extracción (extract), transformación (transform) y carga (load).

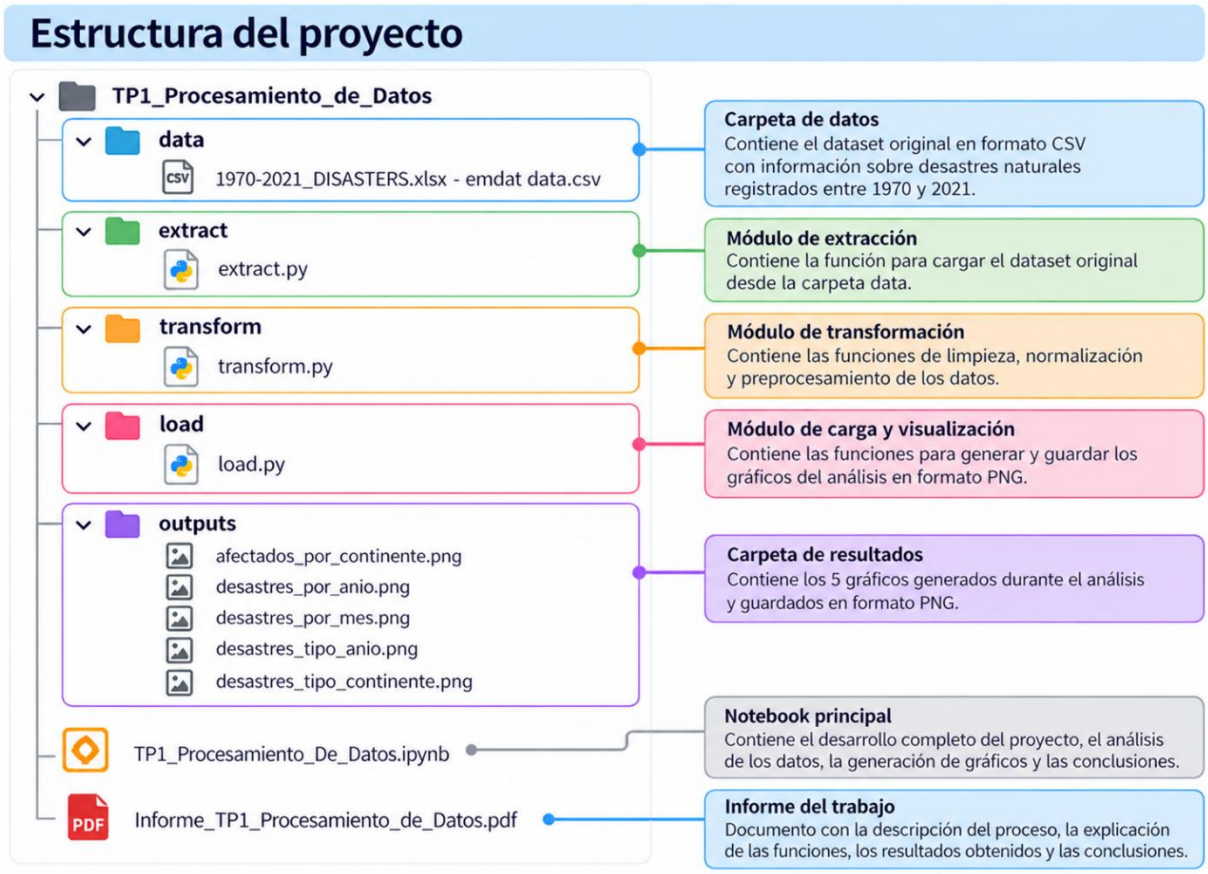
Cada etapa fue implementada mediante funciones de Python agrupadas en módulos independientes:

- Extract (extract/extract.py): se encarga de leer el archivo CSV original utilizando Pandas y cargar su contenido en un DataFrame.
- Transform (transform/transform.py): contiene las funciones destinadas a transformar las fechas, limpiar las variables categóricas y realizar las agrupaciones necesarias para los análisis temporales y geográficos.
- Load (load/load.py): contiene las funciones utilizadas para generar y guardar los gráficos que representan los resultados obtenidos.

Además se utiliza un notebook de Google Colab para ejecutar las distintas etapas del proceso, visualizar los resultados y desarrollar las interpretaciones correspondientes.

Seleccioné esta arquitectura porque permite separar las responsabilidades de cada etapa, facilitando la lectura, el mantenimiento y la reutilización del código.

La organización modular también permite modificar una función o incorporar nuevos análisis sin necesidad de reescribir todo el proyecto.



4. Desarrollo del proceso ETL

4.1. Extracción de datos (Extract)

La primera etapa consiste en la lectura del archivo CSV mediante la librería Pandas.

Para ello, creé la función **extract_data()** dentro del módulo extract.py, que recibe como parámetro la ruta del archivo, utiliza **pd.read_csv()** para cargar los datos y devuelve un DataFrame.

El dataset se almacenó en la carpeta del proyecto y se utilizó una ruta relativa para acceder a él, facilitando su ejecución en diferentes entornos.

Una vez realizada la extracción, verifiqué que los datos estuvieran cargados correctamente mediante **shape**, pudiendo ver que se obtuvo un DataFrame con 14.644 filas y 47 columnas. Con esto pude verificar que el archivo se leyó correctamente.

4.2. Transformación y limpieza de datos (Transform)

La segunda etapa consiste en preparar y transformar los datos originales para facilitar su análisis.

Las transformaciones se implementaron mediante funciones independientes dentro del módulo transform.py.

Transformación de fechas:

Se creó una nueva columna llamada fecha a partir de las variables Start Year y Start Month, utilizando la función **pd.to_datetime()** de Pandas.

Para construir las fechas se asignó el día 1 de cada mes como valor de referencia, ya que el análisis se realiza a nivel mensual y anual, sin necesidad de conocer el día exacto del evento.

Se utilizó **errors="coerce"** para convertir las fechas que no se podían interpretar correctamente en valores faltantes NaT.

```python
def transform_date(df: pd.DataFrame) -> pd.DataFrame:
    df = df.copy()

    df["fecha"] = pd.to_datetime(
        dict(
            year=df["Start Year"],
            month=df["Start Month"],
            day=1
        ),
        errors="coerce"
    )

    return df
```

Limpieza de variables categóricas:

Se aplicó una limpieza a las columnas Disaster Type, Country, Continent y Region, eliminando los espacios en blanco innecesarios mediante **str.strip().**

Además se revisaron los valores únicos de estas variables para detectar posibles inconsistencias en las categorías.

```python
def clean_categories(df: pd.DataFrame) -> pd.DataFrame:
    df = df.copy()

    columnas = ["Disaster Type", "Country", "Continent", "Region"]

    for columna in columnas:
        df[columna] = df[columna].str.strip()

    return df
```

Tratamiento de valores faltantes:

Se identificaron valores faltantes en las siguientes variables numéricas:

Total Deaths: 4.445 valores faltantes.

Total Affected: 3.603 valores faltantes.

Total Damages: 9.781 valores faltantes.

Decidí no reemplazar estos valores por cero, ya que la ausencia de información no significa necesariamente que un desastre no haya provocado víctimas, personas afectadas o daños económicos.

En los análisis que utilizan estas variables se usaron únicamente los registros con información disponible, conservando los datos originales para el resto de los análisis.

4.3. Carga y visualización de resultados (Load)

Esta última etapa consiste en generar y guardar las visualizaciones a partir de los datos previamente transformados.

Para ello, desarrollé funciones dentro del módulo load.py, utilizando la librería Matplotlib.

Realicé 5 gráficos principales:

- Evolución anual de la cantidad de desastres naturales entre 1970 y 2021.
- Distribución de los tipos de desastres por continente.
- Distribución mensual de los desastres naturales.
- Evolución de los cinco tipos de desastres más frecuentes durante el período 2002 – 2021.

- Cantidad total de personas afectadas por continente.

Los gráficos se guardaron como archivos PNG dentro de la carpeta outputs del proyecto.

Luego se incorporaron al notebook de Google Colab, donde se acompañaron con interpretaciones de los resultados obtenidos.

Acá pude presentar la información procesada de manera visual, facilitando la identificación de patrones temporales, diferencias geográficas y tendencias en la ocurrencia de desastres naturales.

4.4. Resumen de las funciones implementadas

A continuación se presentan las funciones desarrolladas en cada módulo del proyecto y su finalidad dentro del proceso ETL.

Módulo	Función	Descripción
Extract	`extract_data()`	Lee el archivo CSV original mediante Pandas y devuelve los datos en un DataFrame.
Transform	`transform_date()`	Crea la columna `fecha` a partir del año y mes de inicio del desastre, utilizando el día 1 como referencia.
	`clean_categories()`	Elimina espacios en blanco al principio y al final de las categorías de tipo de desastre, país, continente y región.
	`disasters_by_year()`	Calcula la cantidad de desastres registrados por año.
	`disasters_by_type_continent()`	Genera una tabla cruzada con la cantidad de desastres según su tipo y continente.
	`disasters_by_month()`	Calcula la cantidad de desastres registrados por mes utilizando la columna `fecha`.
	`disasters_by_type_year()`	Selecciona los cinco tipos de desastres más frecuentes entre 2002 y 2021 y calcula su cantidad anual.
	`affected_by_continent()`	Agrupa los registros por continente y calcula la suma y la cantidad de registros con datos válidos de personas afectadas.
Load	`plot_disasters_by_year()`	Genera y guarda el gráfico de evolución anual de desastres.
	`plot_disasters_by_type_continent()`	Genera y guarda el gráfico de los principales tipos de desastres por continente.
	`plot_disasters_by_month()`	Genera y guarda el gráfico de distribución mensual de desastres.
	`plot_disasters_by_type_year()`	Genera y guarda el gráfico de evolución de los principales tipos de desastres entre 2002 y 2021.
	`plot_affected_by_continent()`	Genera y guarda el gráfico de personas afectadas por continente.

5. Análisis de resultados

Se realizaron diferentes análisis exploratorios para identificar patrones en la ocurrencia de desastres naturales durante el período 1970 – 2021.

Se estudiaron las variaciones en la cantidad de eventos a lo largo de los años, su distribución mensual, las diferencias entre tipos de desastres y continentes, y su evolución durante las últimas dos décadas.

También se analizó la cantidad de personas afectadas por continente, considerando las limitaciones de los registros disponibles.

A continuación, se presentan los principales resultados obtenidos y sus respectivas interpretaciones.

5.1. Evolución de los desastres naturales (1970 - 2021)

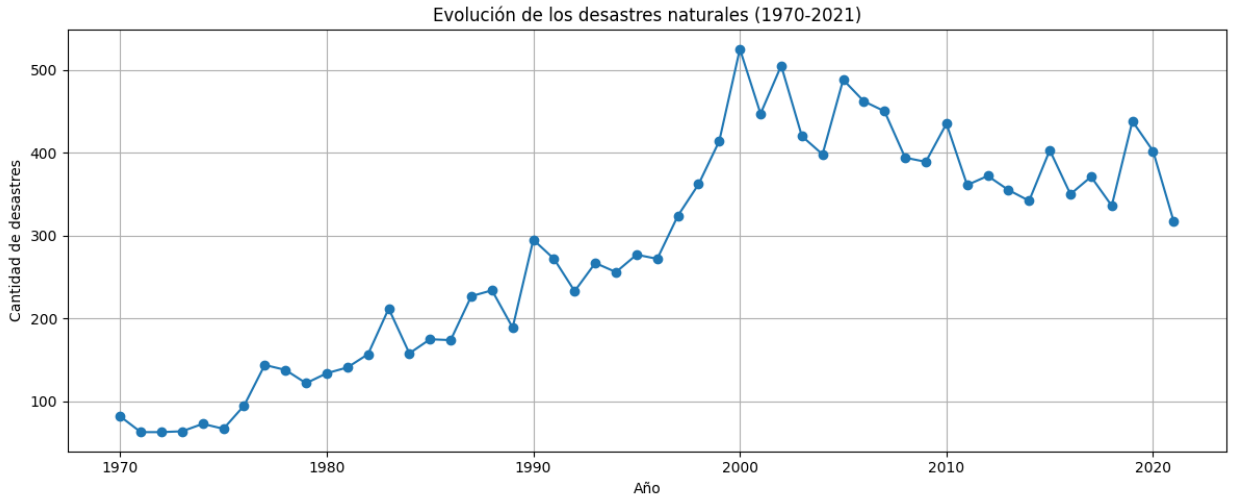


Figura 1 – Evolución de la cantidad de desastres naturales registrados entre 1970 y 2021.

Se observa una tendencia creciente en la cantidad de desastres naturales entre 1970 y 2021.

Durante los primeros años se ve un aumento progresivo, que a partir de 1990 se intensifica, alcanzando el máximo valor en el año 2000, con más de 500 eventos registrados.

Desde allí en adelante, la cantidad de desastres registrados por año presenta fluctuaciones y una disminución del máximo alcanzado, aunque se mantiene en mayor cantidad que de 1970 a 1990.

Podemos identificar el aumento o disminución en la cantidad de eventos registrados, pero lo que no podemos determinar son sus causas.

5.2. Tipos de desastres por continente

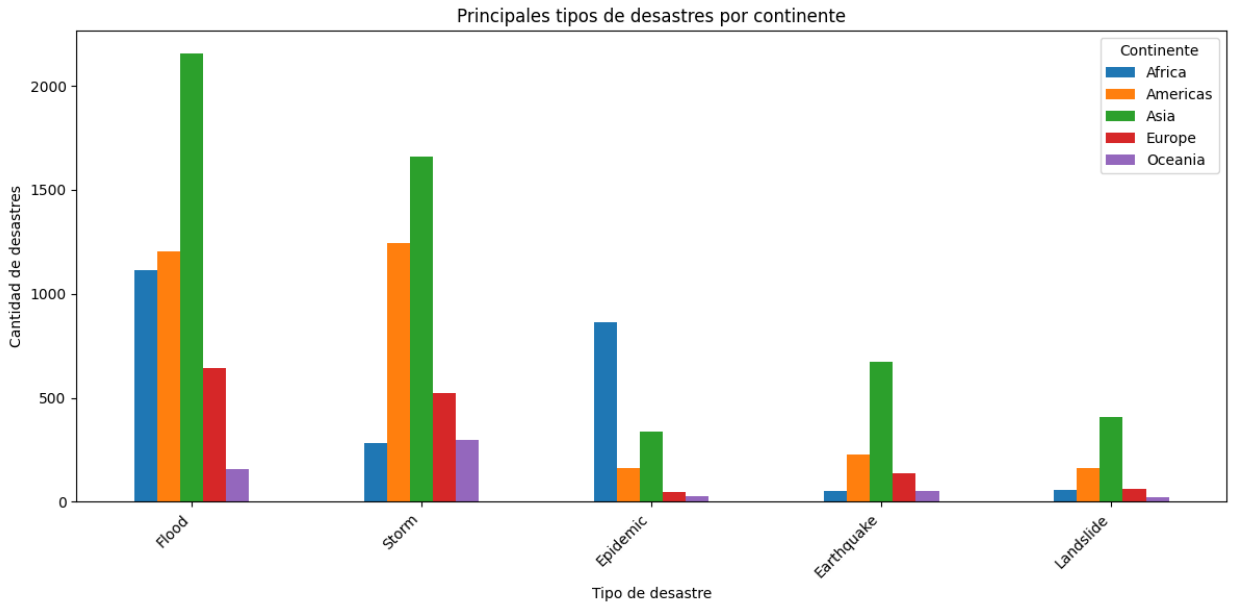


Figura 2 – Distribución de los principales tipos de desastres naturales según el continente (1970 – 2021)

Podemos observar que las inundaciones y las tormentas son los tipos de desastres más frecuentes, y que hay una marcada concentración en Asia. Este continente también presenta la mayor cantidad de terremotos y deslizamientos de tierra, concentrando la mayor cantidad de registros en cuatro de las cinco categorías analizadas.

Por otro lado, observamos que África registra la mayor cantidad de epidemias.

Estos resultados muestran la cantidad de desastres registrados en cada continente, pero sin considerar su tamaño, la cantidad de habitantes ni las diferencias en la forma de registrar los eventos.

Es por eso que no podemos afirmar que un continente sea más peligroso que otro solamente porque tenga más desastres registrados.

5.3. Distribución mensual de los desastres naturales (1970 – 2021)

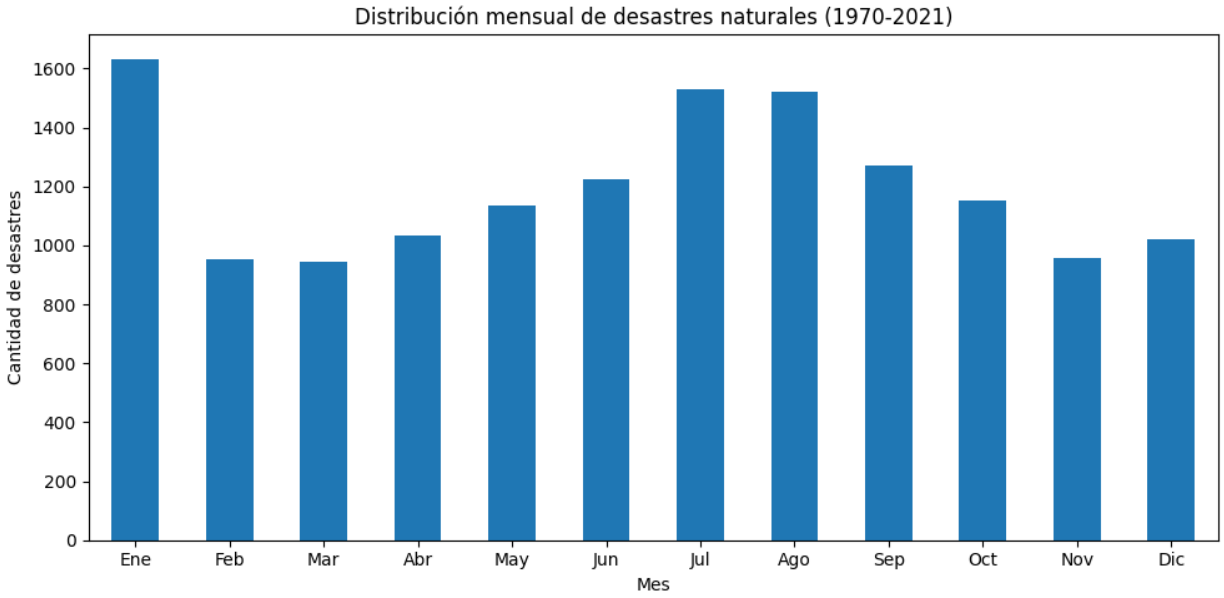


Figura 3 – Distribución mensual de los desastres naturales registrados entre 1970 y 2021

Podemos observar que enero presenta la mayor cantidad de registros, le siguen julio y agosto. Por el contrario, marzo es el mes con menor eventos registrados.

Estas diferencias se podrían relacionar con fenómenos naturales que ocurren con mayor frecuencia en determinadas épocas del año, como tormentas, inundaciones o temperaturas extremas.

Sin embargo, como los datos corresponden a diferentes países y continentes, no podemos asegurar que exista una misma temporada de mayor riesgo en todo el mundo.

5.4. Evolución de los cinco tipos de desastres más frecuentes (2002 – 2021)

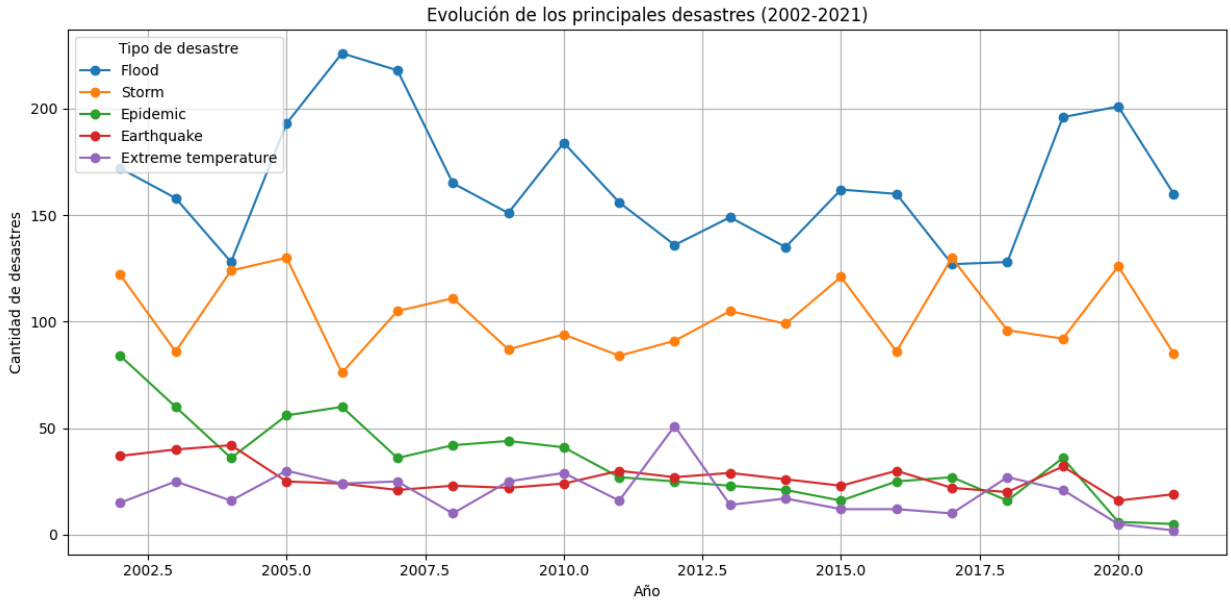


Figura 4 – Evolución anual de los cinco tipos de desastres naturales más frecuentes entre 2002 y 2021.

Las inundaciones fueron los eventos más registrados, seguidas por las tormentas. Ambas presentan aumentos y disminuciones, sin mantener un crecimiento constante.

Las epidemias muestran una disminución en la cantidad de registros, mientras que los terremotos se mantienen más bien estables. Las temperaturas extremas presentan cantidades menores, aunque se ve un aumento importante en el año 2012.

No todos los desastres varían de la misma manera a través de los años, es por eso que lo ideal es analizar cada tipo por separado.

5.5. Cantidad de personas afectadas por continente (1970 – 2021)

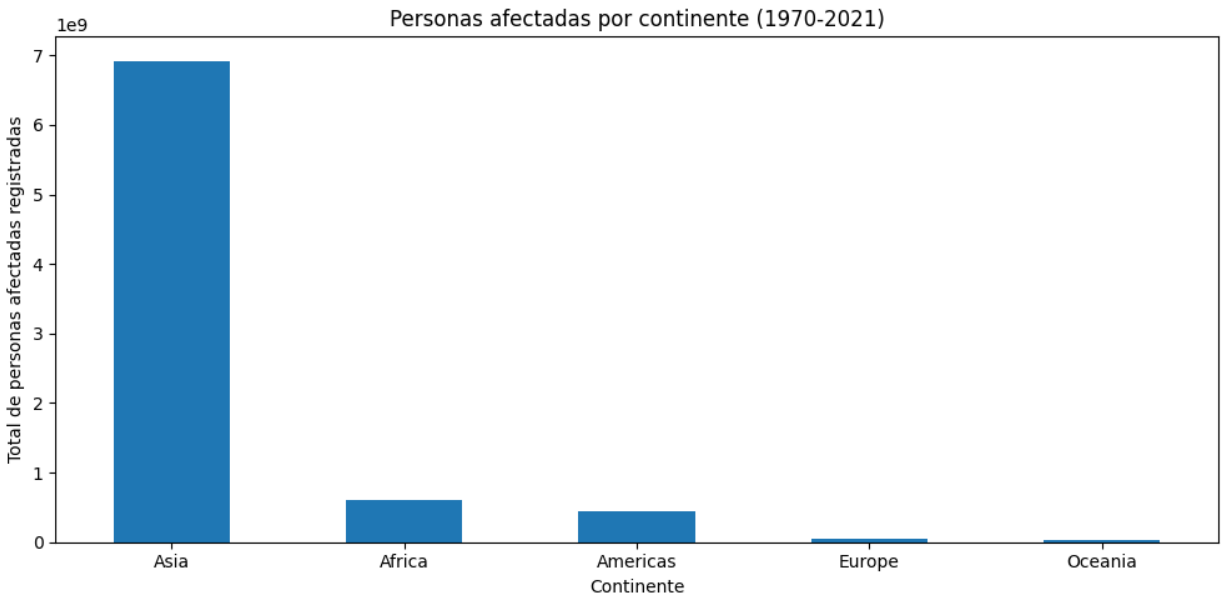


Figura 5 – Total acumulado de personas afectadas por desastres naturales según el continente (1970 – 2021)

Vemos que Asia presenta la mayor cantidad, con aproximadamente 6.923 millones de personas afectadas, superando ampliamente a los demás continentes. Le siguen África y América, y luego con valores mucho menores Europa y Oceanía.

Esta diferencia podría estar relacionada con la gran cantidad de habitantes que tienen algunos países asiáticos. Y además puede haber personas que fueron afectadas por varios eventos y aparecen contabilizadas más de una vez.

Además, algunos desastres no tienen registrada la cantidad de personas afectadas, por lo que los resultados se basan únicamente en los eventos que cuentan con esa información.

6. Conclusiones generales

En este trabajo apliqué un proceso ETL (Extracción, Transformación y Carga) para organizar, limpiar y analizar la información sobre desastres naturales registrados entre 1970 y 2021.

La separación del código en módulos facilitó la organización del proyecto y permitió diferenciar las tareas de extracción, transformación y análisis de los datos. Durante el preprocesamiento se construyó una variable de fecha, se normalizaron las categorías y se

identificaron valores faltantes, evitando reemplazarlos por cero cuando no existía información suficiente.

A partir de los gráficos se identificaron diferencias en la distribución de los desastres según el período, el tipo de evento y el continente. También se observaron variaciones en la evolución de los principales tipos de desastres durante las últimas dos décadas y diferencias en la cantidad acumulada de personas afectadas por continentes.

Los resultados dependen de la información disponible en el dataset. Los valores faltantes y los posibles cambios en los sistemas de registro limitan las interpretaciones, por lo que no es posible atribuir las tendencias observadas a causas específicas únicamente a partir de estos análisis.

Se pudieron integrar herramientas de Python, Pandas y Matplotlib en un proyecto modular, aplicando técnicas de procesamiento de datos y análisis exploratorio para obtener información relevante a partir de un conjunto de datos real.